

문서의 감정 분류를 위한 주목 방법 기반의 딥러닝 인코더

An Attention Method-based Deep Learning Encoder for the Sentiment Classification of Documents

저자 (Authors)	권순재, 김주애, 강상우, 서정연 Sunjae Kwon, Juae Kim, Sangwoo Kang, Jungyun Seo
출처 (Source)	정보과학회 컴퓨팅의 실제 논문지 23(4), 2017.4, 268-273(6 pages) KIISE Transactions on Computing Practices 23(4) , 2017.4, 268-273(6 pages)
발행처 (Publisher)	한국정보과학회 The Korean Institute of Information Scientists and Engineers
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07153956
APA Style	권순재, 김주애, 강상우, 서정연 (2017). 문서의 감정 분류를 위한 주목 방법 기반의 딥러닝 인코더. 정보과학회 컴퓨팅의 실제 논문지, 23(4), 268-273
이용정보 (Accessed)	연세대학교 165.***.14.104 2019/12/09 01:03 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

문서의 감정 분류를 위한 주목 방법 기반의 딥러닝 인코더

(An Attention Method-based Deep Learning Encoder for
the Sentiment Classification of Documents)

권 순 재 [†] 김 주 애 [†] 강 상 우 ^{††} 서 정 연 ^{†††}
(Sunjae Kwon) (Juae Kim) (Sangwoo Kang) (Jungyun Seo)

요 약 최근 감정 분류 분야에서 딥러닝 인코더 기반의 접근 방법이 활발히 적용되고 있다. 딥러닝 인코더 기반의 접근 방법은 가변 길이 문장을 고정 길이 문서 벡터로 압축하여 표현한다. 하지만 딥러닝 인코더에 흔히 사용되는 구조인 장·단기 기억망(Long Short-Term Memory network) 딥러닝 인코더는 문서가 길어지는 경우, 문서 벡터 표현의 품질이 저하된다고 알려져 있다. 본 논문에서는 효과적인 감정 문서의 분류를 위해, 장·단기 기억망의 출력을 중요도에 따라 가중합하여 문서 벡터 표현을 생성하는 주목 방법 기반의 딥러닝 인코더를 사용하는 것을 제안한다. 또한, 주목 방법 기반의 딥러닝 인코더를 문서의 감정 분류 영역에 맞게 수정하는 방법을 제안한다. 제안하는 방법은 윈도우 주목 방법(Window Attention Method)을 적용한 단계와 주목 가중치 재조정(Weight Adjustment) 단계로 구성된다. 윈도우 주목 방법은 한 단어 이상으로 구성된 감정 자질을 효과적으로 인식하기 위해, 윈도우 단위로 가중치를 학습한다. 주목 가중치 재조정에서는 학습된 가중치를 평활화(Smoothing) 한다, 실험 결과, 본 논문에서 제안하는 방법은 정확도 기준으로 89.67%의 성능을 나타내어 장·단기 기억망 인코더보다 높은 성능을 보였다.

키워드: 감정 분류, 딥러닝 인코더, 장·단기 기억망, 주목 방법

Abstract Recently, deep learning encoder-based approach has been actively applied in the field of sentiment classification. However, Long Short-Term Memory network deep learning encoder, the commonly used architecture, lacks the quality of vector representation when the length of the documents is prolonged. In this study, for effective classification of the sentiment documents, we suggest the use of attention method-based deep learning encoder that generates document vector representation by weighted sum of the outputs of Long Short-Term Memory network based on importance. In addition, we propose methods to modify the attention method-based deep learning encoder to suit the sentiment classification field, which consist of a part that is to applied to window attention method and an attention

- 본 연구는 미래창조과학부 및 정보통신기술진흥센터의 정보통신·방송 연구개발 사업[R0126-16-1112, 퍼스널 미디어가 연결공유결합하여 재구성 가능케 하는 복합 모달리티 기반 미디어 응용 프레임워크 개발] 그리고 2017년도 정부(미래창조과학부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임 (NRF-2016R1C1B1014573)
· 이 논문은 2016 한국컴퓨터종합학술대회에서 'LSTM Attention Encoder를 이용한 문서의 감정 분류'의 제목으로 발표된 논문을 확장한 것임

[†] 학생회원 : 서강대학교 컴퓨터공학과
soon91jae@gmail.com
jiu75474@gmail.com

^{††} 정 회 원 : 가천대학교 소프트웨어학과 교수(Gachon Univ.)
gahng.sw@gmail.com
(Corresponding author임)

^{†††} 종신회원 : 서강대학교 컴퓨터공학과 교수
seojy@sogang.ac.kr

논문접수 : 2016년 10월 20일

(Received 20 October 2016)

논문수정 : 2016년 12월 6일

(Revised 6 December 2016)

심사완료 : 2016년 12월 29일

(Accepted 29 December 2016)

Copyright©2017 한국정보과학회 : 개인 목적이거나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회 컴퓨팅의 실제 논문지 제23권 제4호(2017. 4)

weight adjustment part. In the window attention method part, the weights are obtained in the window units to effectively recognize feeling features that consist of more than one word. In the attention weight adjustment part, the learned weights are smoothened. Experimental results revealed that the performance of the proposed method outperformed Long Short-Term Memory network encoder, showing 89.67% in accuracy criteria.

Keywords: sentiment classification, deep learning encoder, long short-term memory network, attention method

1. 서론

최근 소셜 네트워크 서비스, 블로그 등의 발전과 함께 상품평, 영화평, 사용자 피드백 등 사용자 제작 콘텐츠(User-Generated Contents)를 분석하는 연구가 관심을 받고 있다. 특히, 사용자 제작 콘텐츠의 감정을 자동으로 분석하는 경우 저비용으로 인물, 사건, 상품 등에 대한 사용자들의 의견을 분석할 수 있다. 따라서 문서에서 드러나는 감정을 분석하여 이를 자동으로 분류하는 감정 분류에 대한 수요가 늘어나고 있다.

감정 분류의 목적은 특정 문서 혹은 문장이 긍정적인 의도를 갖는지 부정적인 의도를 갖는지를 인식하는 작업이다[1]. 기존에는 감정을 가지는 문장 구성요소인 감정 자질 등을 사용하여 감정을 분석하였다. 하지만 감정 자질을 분석하기 위해서는 지식 베이스, 사전, 규칙, 태깅 데이터 등이 필요하다[2-5]. 따라서 감정 자질을 확장하는 데는 많은 비용이 소요되기 때문에 이를 해결하기 위해, 딥러닝 기반의 접근이 최근 연구되고 있다[6-8], 이 중 가변 길이 문서를 연속 벡터 공간으로 전사하여 의미를 압축하는 딥러닝 인코더(Deep learning encoder) 기반의 접근이 우수한 성능을 보이고 있다[6].

장·단기 기억망(Long Short-Term Memory network; LSTM) 인코더는 입력 시퀀스의 마지막 출력을 문서 벡터 표현으로 간주하는 구조이다[6]. 하지만 문서 분류, 기계 번역 등에서 기존 모델로 많이 사용되는 장·단기 기억망인코더는 긴 패턴을 저장하는 능력이 낮아[9], 문장이 길어짐에 따라 초기 입력 정보를 잊어버리는 문제가 있다[10]. 따라서 긴 문서의 인코더에는 적합하지 않다고 알려져 있다.

본 연구에서는 최근 기계 번역 분야에서 좋은 성능을 보이는 주목 방법(Attention Method) 기반의 딥러닝 인코더[10]를 감정 분류 영역에 적용하고자 한다. 주목 방법 기반의 딥러닝 인코더는 장·단기 기억망의 출력을 중요도에 따라 가중치를 부여하고, 이를 장·단기 기억망의 출력과 가중합하는 구조이다. 따라서 전체 문서의 패턴을 인식해야 하는 장·단기 기억망 인코더와 달리, 주목 방법 기반의 딥러닝 인코더는 감정을 갖는 부분의 패턴만 인식하면 되어, 긴 문서의 인코딩에 적합하다. 또한 본 연구에서는 한 단어 이상의 감정 자질을 효과

적으로 인식하기 위해, 가중치를 윈도우 단위로 학습하는 구조를 제안한다. 마지막으로, 학습된 가중치를 재조정하여, 문서 벡터 표현에 전체 문서의 내용을 효과적으로 반영하는 방법을 제안한다.

2. 관련 연구

2.1 국내외 감정 분류 연구

감정 분류에 관련한 기존 연구에서는 문서에서 감정을 표현하는 어휘 자질을 사용하는 방법이 많이 연구되었다[4,5]. [4]는 각 단어가 갖는 의미적 특성을 수치화하여, 이를 지지 벡터 기계(Support Vector Machine)의 자질로 사용하는 방법을 연구하였다. 또한 [5]에서는 수작업으로 구축한 자질을 감정 분류에 사용하는 방법을 제안하였다.

최근에는 딥러닝을 감정 분류에 사용하는 방법이 활발히 연구되고 있다[6-8,11]. [7]은 원거리 감독(Distant supervision)으로 만든 대규모 말뭉치를 기반으로, 감정 분류에 효과적인 단어 벡터 표현을 학습하였다. 그리고 [8]은 신경망 기반 언어모델(Neural Network Language Model; NNLM) 기반 비지도(Unsupervised) 학습 방법으로 문서를 벡터 표현으로 압축하여 감정 분류의 성능을 높였다. 또한 [11]에서는 문서 길이에 따라 동적으로 풀링(pooling) 크기를 결정하여, 문서가 긴 경우에도 높은 성능을 보이는 DCNN(Dynamic Convolutional Neural Network)를 제안하였다. 마지막으로 [6]에서는 장·단기 기억망을 사용하여 문서를 벡터 표현으로 압축하는 방법을 제안하였다.

2.2 장·단기 기억망 인코더

장·단기 기억망[12]은 순환 신경망(Recurrent Neural Network; RNN)의 기울기 소실(Vanishing gradient) 문제를 셀 상태(Cell state)의 선택적인 갱신을 사용하여 해결하는 구조이다. 장·단기 기억망의 구조는 그림 1과 같다. x_t 는 t번째 입력이고, h_t 는 t번째 출력, c_t 는 t번째 셀 상태이다. f_t 는 잊기 게이트(Forget gate)로 입력 x_t 와 이전 출력 h_{t-1} 에서 이전 셀 상태 c_{t-1} 에 필요한 정보를 선별한다. i_t 는 입력 게이트(Input gate)로 입력과 이전 출력에서 현재 셀 상태 c_t 에 필요한 정보를 선별한다. 마지막으로 o_t 는 출력 게이트(Output gate)로

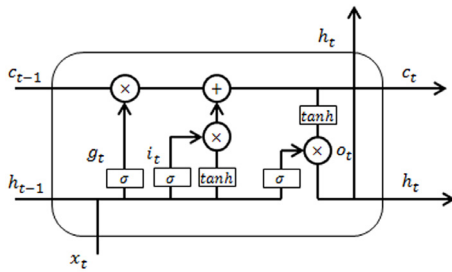


그림 1 장·단기 기억망의 구조

Fig. 1 Structure of LSTM




그림 2 장·단기 기억망 인코더의 구조

Fig. 2 Structure of the LSTM encoder

해당 입력에 대한 출력 h_t 에 필요한 정보를 현재 셀 상태에서 선별한다.

장·단기 기억망 인코더는 전체 장·단기 기억망 은닉층(Hidden Layer)의 마지막 출력 h_n 을 문서 벡터 표현으로 사용하는 구조이다. 예를 들어 그림 2와 같이 “I hate this game.”과 같은 입력의 경우, 마지막 입력 단어 “.”의 출력이 전체 입력을 요약한다고 간주한다. 최상층(Top layer)은 문서 벡터 표현을 분석하여, 해당 문서가 긍정인지 부정인지를 판단하는 앞먹임 신경망(Feed Forward Neural Network; FFNN)이다.

장·단기 기억망 인코더는 구현이 용이하여 딥러닝 인코더의 기본 시스템으로 다양하게 사용된다. 하지만, 장·단기 기억망 인코더는 시퀀스의 마지막 출력을 전체 문장 벡터표현으로 사용하는 구조의 한계 때문에, 초기 입력 패턴 인식률이 떨어진다. 따라서 입력이 길어지는 경우 성능이 급격히 저하되는 문제가 있다[10].

본 논문에서는 최근 기계 번역 등에서 흔히 사용되는 주목 방법 기반의 딥러닝 인코더로 위와 같은 문제를 해결하고자 한다. 또한, 주목 방법 기반 딥러닝 인코더를 감정 분류 영역에 맞게 재설계하여, 감정 분류의 성능을 높이는 방법을 제안한다.

3. 주목 방법 기반의 딥러닝 인코더

3.1 주목 방법 기반의 딥러닝 인코더의 구조

은닉층의 마지막 출력을 문서 벡터 표현으로 사용하는

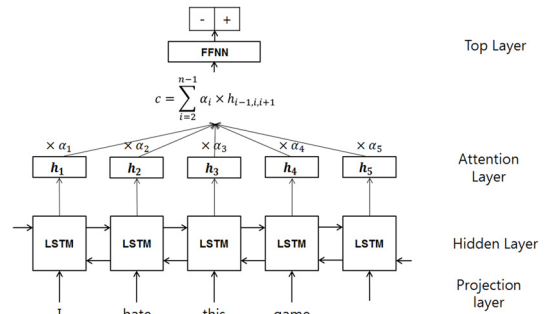


그림 3 주목 방법 기반의 딥러닝 인코더의 구조

Fig. 3 Structure of the attention method-based deep learning encoder

장단기 기억망 인코더와 달리 주목 방법 기반의 딥러닝 인코더는 은닉층의 결과를 가중합하여 문서 벡터 표현을 결정한다. 식 (1)은 문서 길이가 n 인 주목 방법 기반의 딥러닝 인코더의 동작 과정이다.

$$f(h_i) = \tanh(W_1 h_i + b_1)$$

$$\alpha_i = \frac{e^{f(h_i)}}{\sum_{j=1}^n e^{f(h_j)}}$$

$$c = \sum_{i=1}^n \alpha_i \times h_i \quad (1)$$

식 (1)에서 f 는 중요도 함수로 앞먹임 신경망으로 구현한다. 이때 W_1 는 앞먹임 신경망의 가중치 행렬(weight matrix)이고, b_1 는 편향(bias)이다. 중요도 함수는 은닉층의 출력 벡터 h_i 를 입력으로 받아 해당 출력의 감정 점수를 -1~1사이로 부여한다. 주목 가중치 α_i 는 중요도 함수의 결과 $\{f(h_1) \dots f(h_n)\}$ 를 softmax 활성화 함수에 적용하여 확률 변수로 변환한 결과이다. 문서 벡터 c 는 은닉층 출력 $\{h_1 \dots h_n\}$ 과 주목 가중치 $\{\alpha_1 \dots \alpha_n\}$ 의 가중치 합이다. 이 경우, 문서 벡터 c 는 주목 가중치가 높은 은닉층 출력이 높게 반영된다. 예를 들어 그림 3과 같이 “I hate this game.”이라는 문장이 들어오는 경우, 감정 자질인 ‘hate’의 은닉층 결과 h_2 의 가중치가 가장 큰 값을 갖는다. 따라서 문서 벡터 c 에 ‘hate’가 다른 단어에 비해 강조되어, 문서가 부정적으로 분류된다.

3.2 윈도우 주목 방법 기반의 딥러닝 인코더의 구조

문서에서 감정 자질은 그림 3의 ‘hate’ 등과 같이 한 단어인 경우도 있다. 하지만 많은 문서에서 감정 자질은 표 1의 이모티콘 혹은 숙어와 같이 1개 이상의 단어가 모여서 구성된다. 이때, 3.1절의 방법과 같이 가중치를 부여하는 경우, 이모티콘이나 숙어의 어떤 단어에 가중

표 1 감정 자질의 예시

Table 1 Examples of feeling features

Constituent of sentence	Example
Words	hate, love, disgust ...
Emoticons	:D, :(, :O ...
Idioms	can't wait, face the music ...

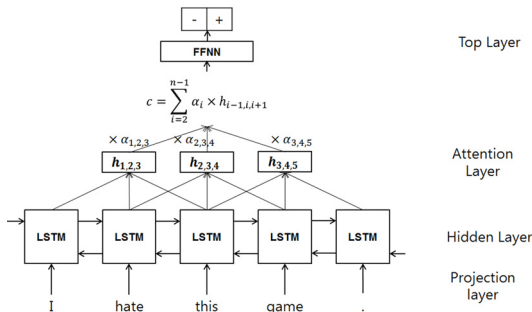


그림 4 윈도우 크기가 3인 주목 방법 기반의 딥러닝 인코더의 구조

Fig. 4 Structure of the attention method-based deep learning encoder of window size of 3

치를 얼마나 주어야 하는지가 매우 불분명하다. 따라서 이모티콘이나 숙어 등이 갖는 감정 표현을 인식하기가 어려움이 따른다.

본 논문에서는 문서 벡터 표현을 생성 시, 은닉층의 각 결과를 가중합하는 구조를 변경하여, 윈도우 단위로 가중합하는 구조를 제안한다. 제안하는 모델은 식 (2)와 같이, 은닉층의 결과를 주어진 윈도우 크기 w 만큼 결합하여 주목층(Attention Layer)에서 가중치를 계산한다. 예를 들어, 윈도우 크기가 3이고 전체 문서가 “I hate this game.”인 경우 그림 4와 같은 구조를 갖는다. 이때, 감정 단어가 포함된 “I hate this”와 “hate this game” 윈도우가 “this game.” 윈도우보다 높은 주목 가중치 α 를 가져 전체 문서 벡터 표현 c 가 부정적으로 표현된다.

$$\alpha_{i-w/2, \dots, i+w/2} = \frac{e^{f(h_{i-w/2, \dots, i+w/2})}}{\sum_{j=w/2+1}^{n-w/2} e^{f(h_{j-w/2, \dots, j+w/2})}} + \epsilon$$

$$c = \sum_{i=w/2+1}^{n-w/2} \alpha_{i-w/2, \dots, i+w/2} \times h_{i-w/2, \dots, i+w/2} \quad (2)$$

3.3 주목 가중치 재조정

3.1절과 3.2절에서 제안한 주목 기반의 딥러닝 인코더의 경우 주목 가중치 α 를 계산 할 때, softmax 함수를 사용하여 전체 주목 가중치의 합이 1인 확률 변수 형태로 변환한다. 하지만 softmax 함수의 분자는 밑이 자연 상수 e 인 지수함수 형태이기 때문에, 중요도 함수 f 의

결과가 높은 일부 구문의 주목 가중치는 매우 높고, 대부분의 구문의 주목 가중치는 0에 가까운 값을 갖는다. 이 경우, 문서 벡터 표현에 주목 가중치가 높은 일부 구문만 반영되어 문서 벡터 표현에 대부분의 정보가 소실된다. 본 연구에서는 식 (3)과 같이 각 주목 가중치에 매우 작은 재조정 값 ϵ 을 더하여 가중치를 재조정하는 방법을 제안한다. 이 방법을 통해 주목 가중치의 편차를 줄여, 가중치가 낮게 학습된 문장 구성요소가 문서 벡터 표현 c 에 더 많이 반영 될 수 있다.

$$\alpha_{i-w/2, \dots, i+w/2} = \frac{e^{f(h_{i-w/2, \dots, i+w/2})}}{\sum_{j=w/2+1}^{n-w/2} e^{f(h_{j-w/2, \dots, j+w/2})}} + \epsilon \quad (3)$$

4. 실험 및 결과

4.1 실험환경

본 연구에서는 “Stanford IMDB movie review”¹⁾ 말뭉치를 사용하여, 본 논문에서 제안하는 구조를 평가하였다. 해당 말뭉치는 영화평 전문 사이트 IMDB²⁾의 유저의 영화평을 수동으로 긍정 부정 태그를 부착한 데이터이다. 표 2와 같이 각 문서 당 평균길이 254단어이고, 학습데이터 24,600문서, 실험 데이터 25,000문서, 검증 데이터 400문서이다.

표 2 말뭉치의 구성

Table 2 Corpus constitution

	Polarity		Total
	Positive	Negative	
Training Data	12,300	12,300	24,600
Test Data	12,500	12,500	25,000
Validation Data	200	200	400

딥러닝 인코더 구조는 아래와 같이 설계하였다. 우선 입력 단어는 대조 테이블(Look-up Table)에 저장된 100차원 벡터로 표현한다. 중요도 함수 f 의 은닉 노드의 개수는 100개이고, 최상층(Top layer)의 은닉 노드 개수는 200개이다. 또한, 모델의 과적합(Overfitting)을 방지하기 위해 최상층에 Dropout[13]을 적용한다. 이때, Dropout의 탈락률(Drop rate)은 0.5로 설정하였다. 윈도우 크기와 가중치 재조정 값 ϵ 은 그림 5와 그림 6의 결과와 같이, 검증 데이터에서 가장 높은 성능을 보인 윈도우 크기 3, 가중치 재조정 값은 0.1/문서 길이로 설정하였다.

4.2 실험 결과

표 3은 본 연구에서 수행한 ‘Stanford IMBD movie

1) http://ai.stanford.edu/~amaas/data/sentiment/aclImdb_v1.tar.gz

2) <http://www.imdb.com/>




그림 5 윈도우 크기에 따른 성능 변화

Fig. 5 Change of performance according to window size




그림 6 재조정 값에 따른 성능 변화

Fig. 6 Change of performance according to adjustment weight

표 3 감정 분류 성능 평가

Fig. 3 Estimation of sentiment classification performance

Test Model	Accuracy
LSTM Encoder	86.50%
Attention based deep learning Encoder	89.10%
+Window Attention Method	89.49%
+Weight adjustment	89.67%
DCNN[11]	89.4%

review' 말뭉치에서의 모델의 성능이다. 실험은 비교 모델인 장·단기 기억망 인코더의 성능을 주목 방법 기반의 딥러닝 인코더와 비교한다. 그리고 주목 방법 기반의 딥러닝 인코더에 윈도우 단위의 주목과 가중치 재조정을 차례로 적용하여, 각 방법이 성능 향상에 미치는 영향을 분석한다. 또한, 기존에 긴 문서의 인코딩을 위해 제안된 DCNN[11]과의 비교를 통해 제안하는 인코더의 성능을 분석한다.

실험 결과 장·단기 기억망 인코더의 성능은 정확도 기준으로 86.50%로 문서의 패턴 인식률이 매우 떨어졌다. 주목 방법 기반의 딥러닝 인코더의 경우 89.10%의 성능을 보여 장·단기 기억망 인코더 보다 2.60%p 성능

이 향상되었다. 그리고 윈도우 단위로 주목 가중치를 학습하여 딥러닝 인코더를 구성하는 경우 89.49%의 성능을 보였다. 그리고 주목 가중치를 재조정하는 경우 89.67%의 성능을 보여, 최종적으로 장·단기 기억망 인코더 보다 3.17%p 성능이 향상되었다. 이 같은 실험 결과를 통해, 장·단기 기억망 인코더 보다 주목 방법 기반의 딥러닝 인코더가 문서의 감정 분류 영역에 더 적합하다는 것을 알 수 있었다. 또한, 윈도우 단위의 주목 방법과 주목 가중치 재조정이 감정 문서 분류의 성능을 높인다는 것을 확인할 수 있었다. 또한, [11]에서 제안된 DCNN 보다 높은 성능을 보여, 제안하는 방법이 감정 문서 인코딩에 적합하다는 것을 확인할 수 있었다.

하지만 제안하는 방법은 은닉층 결과의 단순 가중치로 문서 인코딩을 생성한다. 따라서 문서의 전체 의미가 긍정 혹은 부정일지라도 일부 감정 자질이 높은 가중치를 갖는 경우 해당 감정 자질에 따라 전체 의미가 결정되는 경향이 있다. 예를 들어, 실험 데이터의 "more suspense ful, more subtle, much, much more disturbing..."이라는 문서는 "disturbing"이 강조되어, 부정으로 분류되어야 한다. 하지만 실험 결과, 강력한 부정적 감정 자질 "disturbing"보다, 비교적 약한 긍정 감정 자질인 "subtle"이 더 높은 가중치를 갖게 학습되어 문서가 긍정적으로 분류되는 문제가 발생하였다.

5. 결론 및 향후 연구

본 논문에서는 감정 분류 분야에 주목 방법 기반의 딥러닝 인코더를 사용하는 방법을 제안하였다. 실험 결과 본 논문에서 제안하는 방법은 장·단기 기억망 인코더보다 3.17%p 높은 성능을 보였다.

향후 연구로는 인코더의 구조를 변경하여 가중치 학습 시 해당 구성요소의 단순 감정 가중치 뿐만 아니라, 긍정 가중치와 부정 가중치를 자동으로 분석하고, 이를 바탕으로 더욱 섬세한 감정 분류를 할 수 있도록 설계하는 연구를 수행할 것이다.

References

- [1] Yang, Changhua, et al., "Emotion classification using web blog corpora," *IEEE/WIC/ACM International Conference on IEEE*, pp. 275-278, 2007.
- [2] Montejo-Ráez, Arturo et al., "Ranked wordnet graph for sentiment polarity classification in twitter," *Computer Speech&Language*, Vol. 28, No. 1, pp. 93-107, 2014.
- [3] Tsai, Angela Charng-Rurng, et al., "Building a concept-level sentiment dictionary based on common-sense knowledge," *IEEE Intelligent Systems*, Vol. 28, No. 1, pp. 93-107, 2014.
- [4] Saif Mohammad, et al., "NRC-Canada: Building the

- state-of-the-art in sentiment analysis of tweets," *SemEval-2013*, pp. 321-327, 2013.
- [5] Jaewon Hwang and Youngjoong Ko, "A Document Sentiment Classification System Based on the Feature Weighting Method Improved by Measuring Sentence Sentiment Intensity," *Journal of KIISE : Software and applications*, Vol. 36, No. 6, pp. 491-497, 2009. (In Korean)
- [6] Johnson, Rie, and Tong Zhang, "Supervised and Semi-Supervised Text Categorization using One-Hot LSTM for Region Embeddings," *arXiv preprint arXiv:1602.02373*, 2016.
- [7] Tang, Duyu, et al., "Learning Sentiment-Specific Word Embedding for Twitter Sentiment Classification," *ACL 2014*, pp. 1555-1565, 2014.
- [8] Le, Quoc V and Tomas Mikolov, "Distributed Representations of Sentences and Documents," *ICML 2014*, Vol. 14, pp. 1188-1196, 2014.
- [9] Graves, Alex, Greg Wayne, and Ivo Danihelka, "Neural Turing Machines," *arXiv preprint arXiv:1410.5401*, 2014.
- [10] Dzmitry Bahdanau, KyungHyun Cho and Yoshua Bengio, "Neural Machine Translation by Jointly Learning to Align and Translate," *arXiv preprint arXiv:1409.0473*, 2014.
- [11] Nal Kalchbrenner, Edward Grefenstette and Phil Blunsom, "A Convolutional Neural Network for Modelling Sentence," *Proc. of the 52nd Annual Meeting of the Association for Computational Linguistics*, pp. 655-665, 2014.
- [12] Hochreiter, Sepp, and Jürgen Schmidhuber, "Long Short-Term Memory," *Neural computation*, Vol. 9, No. 8, pp. 1735-1780, 1997.
- [13] Srivastava, Nitish, et al., "Dropout: a simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, Vol. 15, No. 1, pp. 1929-1958, 2014.



권 순 재

2015년 서강대학교 컴퓨터공학과 학사
2017년 서강대학교 컴퓨터공학과 석사
2017년~현재 울산과학기술원 연구원. 관심분야는 자연어처리, 기계학습, 정보추출, 정보검색



김 주 애

2015년 서강대학교 컴퓨터공학과 학사
2017년 서강대학교 컴퓨터공학과 석사
2017년~현재 서강대학교 컴퓨터공학과 박사 과정. 관심분야는 자연어처리, 정보 검색, 정보 추출, 기계학습, 심층학습



강 상 우

2012년 서강대학교 컴퓨터공학과 박사
2012년~2016년 서강대학교 연구교수
2016년~현재 가천대학교 소프트웨어학과 교수. 관심분야는 자연어 처리, 음성 대화 처리, 정보 검색, 정보 추출



서 정 연

1981년 서강대학교 수학과 학사. 1985년 미국 Univ. of Texas, Austin 전산학과 석사. 1990년 미국 Univ. of Texas, Austin 전산학과 박사. 1990년~1991년 미국 Texas Austin, UniSQL Inc. Senior Researcher. 1991년 한국과학기술원 인공지능 연구센터 선임연구원. 1991년~1995년 한국과학기술원 전산학과 교수. 1995년~현재 서강대학교 컴퓨터공학과 교수. 관심분야는 한국어 정보처리, 자연어처리, 기계번역, 대화처리