### In [46]:

```
# import matplotlib.pyplot as plt

# plt.rcParams["font.family"] = 'NanumBarunGothicOTF'

#plt.rcParams["font.size"] = 20

#plt.rcParams["figure.figsize"] = (14,4)
```

### In [57]:

```
from matplotlib import rc, font_manager

path = 'C:/Windows/Fonts/NanumBarunGothic.ttf'
font = font_manager. FontProperties(fname=path).get_name()
rc('font', family=font)
```

### In [59]:

```
from nltk.tag.stanford import StanfordPOSTagger

MODEL = r'C:WUsersWUSERWDesktopWstanford-postagger-full-2018-10-16WmodelsWenglish-bidirectional-distsim.tagger'

PARSER = r'C:WUsersWUSERWDesktopWstanford-postagger-full-2018-10-16Wstanford-postagger-3.9.2.ja
r'
pos = StanfordPOSTagger(MODEL, PARSER)
```

### In [60]:

```
from nltk.tokenize import word_tokenize, sent_tokenize
pos.tag(word_tokenize(sent_tokenize(corpus)[0]))
```

```
0SFrror
                                        Traceback (most recent call last)
<ipvthon-input-60-8d3c13bbc935> in <module>
      1 from nltk.tokenize import word tokenize, sent tokenize
----> 3 pos.tag(word tokenize(sent tokenize(corpus)[0]))
C:\ProgramData\Anaconda3\Uib\site-packages\nltk\tag\stanford.py in tag(self, to
kens)
    91
           def tag(self. tokens):
    92
               # This function should return list of tuple rather than list of
list
---> 93
               return sum(self.tag sents([tokens]), [])
    94
    95
           def tag_sents(self, sentences):
C:\ProgramData\Anaconda3\Iib\site-packages\nltk\tag\stanford.pv in tag sents(se
If. sentences)
   114
               # Run the tagger and get the output
   115
               stanpos_output, _stderr = java(
--> 116
                   cmd, classpath=self._stanford_jar, stdout=PIPE, stderr=PIPE
   117
   118
               stanpos_output = stanpos_output.decode(encoding)
C:\ProgramData\Anaconda3\Iib\site-packages\nltk\Internals.py in java(cmd, class
path, stdin, stdout, stderr, blocking)
   135
   136
           # Call java via a subprocess
--> 137
           p = subprocess.Popen(cmd, stdin=stdin, stdout=stdout, stderr=stderr)
   138
           if not blocking:
   139
               return p
C:\ProgramData\Anaconda3\Iib\subprocess.py in __init__(self, args, bufsize, exe
cutable, stdin, stdout, stderr, preexec_fn, close_fds, shell, cwd, env, univers
al_newlines, startupinfo, creationflags, restore_signals, start_new_session, pa
ss_fds, encoding, errors, text)
                                      c2pread, c2pwrite.
   773
   774
                                      errread, errwrite.
--> 775
                                      restore signals, start new session)
   776
               except:
   777
                   # Cleanup if the child failed starting.
C:\ProgramData\Anaconda3\lib\subprocess.py in _execute_child(self, args, execut
able, preexec fn. close fds. pass fds. cwd. env. startupinfo, creationflags, sh
ell, p2cread, p2cwrite, c2pread, c2pwrite, errread, errwrite, unused_restore_si
gnals, unused start new session)
  1176
   1177
                                               os.fspath(cwd) if cwd is not Non
e else None.
-> 1178
                                               startupinfo)
   1179
                   finally:
  1180
                       # Child is launched. Close the parent's copy of those pi
OSError: [WinError 193] %1은(는) 올바른 Win32 응용 프로그램이 아닙니다
```

#### In [4]:

```
def splitTerm(term):
    result = list()
    for token in term.split():
        result.append(' '.join(list(term) + ['</w>']))
    return '_'.join(result)
```

### In [6]:

```
def ngram(data, n=2):
    result = defaultdict(int)

for term, freq in data.items():
    tokens = term.split()
    for i in range(len(tokens) - (n-1)):
        result[' '.join(tokens[i:i+n])] += freq
return result
```

### In [52]:

```
from nltk import Text
from nltk.tokenize import sent_tokenize, word_tokenize
from konlpy.corpus import kolaw. kobill
corpus = kolaw.open(kolaw.fileids()[0]).read()
def eoieol(text. n =2):
   tokens = text.split()
   ngram = list()
   for i in range(len(tokens)-(n-1)):
       ngram.append(' '.ioin(tokens[i:i+n]))
   return naram
for _ in sent_tokenize(corpus):
   print(eoieol( ))
   break
def umieol(text. n =2):
   ngram = list()
   for i in range(len(text)-(n-1)):
       ngram.append(''.join(text[i:i+n]))
   return naram
for _ in sent_tokenize(corpus):
   print(umjeol(_))
   break
```

'대한민국헌법 유구한'. '유구한 역사와'. '역사와 전통에'. '전통에 빛나는'. '빛나는 우리', '우리 대한국민은', '대한국민은 3·1운동으로', '3·1운동으로 건립된', '건립 된 대한민국임시정부의', '대한민국임시정부의 법통과', '법통과 불의에', '불의에 항거 한'. '항거한 4·19민주이념을', '4·19민주이념을 계승하고.', '계승하고, 조국의' '조국의 민주개혁과'. '민주개혁과 평화적'. '평화적 통일의'. '통일의 사명에'. '사명 에 입각하여'. '입각하여 정의·인도와', '정의·인도와 동포애로써', '동포애로써 민족 의', '민족의 단결을', '단결을 공고히', '공고히 하고,', '하고, 모든', '모든 사회 적', '사회적 폐습과', '폐습과 불의를', '불의를 타파하며,', '타파하며, 자율과', '지 율과 조화를', '조화를 바탕으로', '바탕으로 자유민주적', '자유민주적 기본질서를' '기본질서를 더욱', '더욱 확고히', '확고히 하여', '하여 정치·경제·사회·문화의', '정치·경제·사회·문화의 모든'. '모든 영역에'. '영역에 있어서'. '있어서 각인의'. '각인의 기회를', '기회를 균등히', '균등히 하고,', '하고, 능력을', '능력을 최고도 로'. '최고도로 발휘하게'. '발휘하게 하며.'. '하며. 자유와'. '자유와 권리에'. '권리 에 따르는', '따르는 책임과', '책임과 의무를', '의무를 완수하게', '완수하게 하여,' '하여, 안으로는', '안으로는 국민생활의', '국민생활의 균등한', '균등한 향상을', '힝 상을 기하고', '기하고 밖으로는', '밖으로는 항구적인', '항구적인 세계평화와', '세계 평화와 인류공영에'. '인류공영에 이바지함으로써'. '이바지함으로써 우리들과'. '우리 들과 우리들의'. '우리들의 자손의'. '자손의 안전과'. '안전과 자유와'. '자유와 행복 을', '행복을 영원히', '영원히 확보할', '확보할 것을', '것을 다짐하면서', '다짐하면 서 1948년', '1948년 7월', '7월 12일에', '12일에 제정되고', '제정되고 8차에', '8차 에 걸쳐', '걸쳐 개정된', '개정된 헌법을', '헌법을 이제', '이제 국회의', '국회의 의 결을', '의결을 거쳐', '거쳐 국민투표에', '국민투표에 의하여', '의하여 개정한다.'] ['대한', '한민', '민국', '국헌', '헌법', '법\n', '\n\n', '\n\n', '\n\n', '유구', '구한 ' 역'. '역사', '사와', '와 '. ' 전', '전통', '통에', '에 '나는'. '는 '. ' 우'. '우리'. '리 '. '대', '대한', '한국', '국민', '민은', '은 ' ' • 1' . '1운' . '운동' . '동으' . '으로' . '로 ' 대', '대한', '한민', '민국', '국임', '임시', '시정 '의에', '에 ' · 1', '19', '9민', '민주', '주이', '4 · '. '계승', '승하', '하고', '고.'. ' 조', '조국', '국의' 1 0] 민'. '민주'. '주개'. '개혁'. '혁과'. '과 '. ' 평', '평화', '화적', '통일'. '일의'. '의 '. ' 사'. '사명'. '명에'. '에 '. ' 입'. '입각'. '각하'. '하 . '정의'. '의 · '. '·인', '인도', 정' '도와'. '와'. '포애'. '애로', '로써', '써 ', ' 민', '민족', '족의', '의 '공고', '고히', '히 하'. '하고', '고, '. ' 샤' '사회'. '회적'. '적 '. ' 폐'. '폐습'. '습과'. ' 를 ' 타'. '타파'. '파하'. '하며' '며. ' 고⊦ 조၂. '조화'. '화를 름 바'. '바탕'. '탕으'. '으로', '루 자', '자유', '유민', '민주'. '주적'. '적 ' 기'. '기본'. '본질'. '질서'. '서름' '더욱'. '욱 확'. '확고'. '고히'. '히 '. '하'. '치 · ' ' · 경 ', '경제 ' 제 '·사'. '사회'. '화의' '의 모'. '모든'. ' 영'. '영역'. '역에'. ' 든 '어서'. '서 ' 기'. '기회 ' 각'. '각인'. '인의'. '의 '균등', '등히', '히 '하', '고. '하고'. 능'. 최'. '최고'. '고도'. '도로'. '로 '. 발'. '발휘 '휘하 하'. '하며'. '며.'. '. '자'. '자유'. '유와'. '와 따'. '따르', '르는', '는 ', 책', '책임', '임과', '과 ' 와 ' '완수'. '수하'. '하게'. '게 '하'. '하여'. '여.'. '안으'. '으로'. '로는'. '는 국 '국민'. '민생 균'. '균등'. '등한'. '한 향'. '향상'. '상을'. '을 '밖으'. '으로'. '로는'. '는 ' 항'. '항구'. '구적'. '세계'. '계평'. '평화'. '화와'. '와 '인' '. '인류' 에', '에 ', '이', '이바', '바지', '지함', '함으', '으로', '로써', '우리'. '리들'. '들과'. '과 '. ' 우'. '우리'. '리들'. '들의'. '의 '. ' 자'. '자 손', '손의', '의 '. ' 안'. '안전'. '전과'. '과 자', '자유', '유와', '와 '. '복을', '을 ' 영', '영원', '원히', ' ō∣ ' 것'. '것을'. '을 ' 다'. '다짐'. '짐하'. '하면'. '면서'. '서 '19', '94', '48', '8년', '년 ', ' 7', '7월', '월 '12'. '2일 ', '제', '제정', '정되', '되고', '고', '8', '8차', '차에', '에', 쳐', '쳐', '개', '개정', '정된', '된', '헌', '헌법', '법을', '을 '. ' 01'. '01 제', '제 ', '국', '국회', '회의', '의 ', '의', '의결', '결을', '을 ', ' 거', '거

```
'여'. '개'. '개정'. '정한'. '한다'. '다 ']
In [16]:
from nltk import punkt
from collections import defaultdict
import re
def mergerNgram(maxKey, data):
   newData = dict()
   for term. freq in data.items():
       newKey = re.sub(maxKey, maxKey.replace(' ', ''), term)
       newData[newKey] = freq
   return newData
data = {
   splitTerm('low'):5,
   splitTerm('lowest'):2.
   splitTerm('newer'):6,
   splitTerm('wider'):3
for _ in range(5):
   bigram = ngram(data)
   maxKev = max(bigram, kev=bigram.get)
   data = mergerNgram(maxKey, data)
In [86]:
nltk.download()
showing info https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml
Out[86]:
True
In [88]:
import nltk
import re
from string import punctuation
#n/tk.down/oad('punctuation')
#nltk.download('averaged_perceptron_tagger')
sentence = "She sells seashells on the seashore."
tokens = word_tokenize(sentence.lower())
tokens = [_ for _ in tokens if not re.search(r"[{0}]".format(punctuation), _)]
print(tokens)
['she', 'sells', 'seashells', 'on', 'the', 'seashore']
```

쳐', '쳐 ', ' 국', '국민', '민투', '투표', '표에', '에 ', ' 의', '의하', '하여',

```
In [18]:
from nltk import pos_tag
from nltk.help import upenn tagset
pos tag(tokens)
Out[18]:
[('she', 'PRP').
 ('sells', 'VBZ').
 ('seashells', 'NNS'),
 ('on', 'IN'),
 ('the', 'DT'),
 ('seashore', 'NN').
 ('.', '.')]
In [19]:
nitk.download('gutenberg')
[nltk_data] Downloading package gutenberg to
[nltk_data]
               C:WUsersWUSERWAppDataWRoamingWnltk_data...
[nltk_data] Package gutenberg is already up-to-date!
Out[19]:
True
In [20]:
nltk.download('corpus')
[nltk data] Error loading corpus: Package 'corpus' not found in index
Out [20]:
False
In [21]:
nltk.download("averaged perceptron tagger")
nltk.download("tagsets")
[nltk_data] Downloading package averaged_perceptron_tagger to
               C:WUsersWUSERWAppDataWRoamingWnltk data...
[nltk data]
[nltk_data]
              Package averaged_perceptron_tagger is already up-to-
[nltk data]
                  date!
[nltk_data] Downloading package tagsets to
[nltk_data]
              C:WUsersWUSERWAppDataWRoamingWnltk_data...
[nltk_data] Package tagsets is already up-to-date!
Out[21]:
```

True

```
In [22]:
```

```
from nltk.corpus import gutenberg
#n/tk.down/oad()

corpus = gutenberg.open("austen-emma.txt").read()
posTags = pos_tag(word_tokenize(corpus.lower()))
```

### In [23]:

```
import nltk
nltk.download('tagsets')

upenn_tagset("IN")
upenn_tagset("DT")
```

IN: preposition or conjunction, subordinating astride among uppon whether out inside pro despite on by throughout below within for towards near behind atop around if like until below next into if beside ...

DT: determiner

all an another any both del each either every half la many much nary neither no some such that the them these this those

### In [24]:

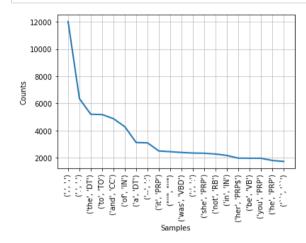
```
[_[0] for _ in pos_tag(tokens) if _[1] not in ["DT", "IN"]]
```

# Out[24]:

```
['she', 'sells', 'seashells', 'seashore', '.']
```

### In [26]:

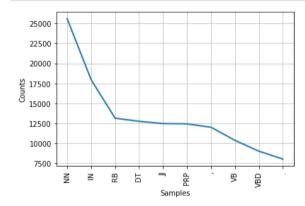




None

### In [27]:

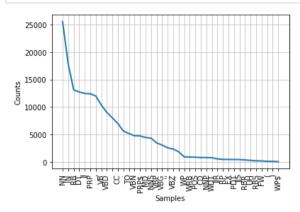
print(Text([\_ [1] for \_ in posTags]).plot(10))



None

### In [28]:

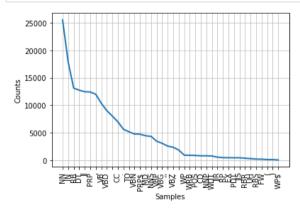
print(Text([\_ [1] for \_ in posTags]).plot())



None

### In [52]:

print(Text([\_ [1] for \_ in posTags]).plot(50))



None

### In [89]:

```
sentence = "The little yellow dog barked at the Persian Cat."

tokens = word_tokenize(sentence.lower())
tokens = [_ for _ in tokens if not re.search(r"[{0}]".format(punctuation), _)]

print(tokens)

print(pos_tag(tokens))
print([_[0] for _ in pos_tag(tokens) if _[1] not in ["DT", "IN"]])
```

```
['the', 'little', 'yellow', 'dog', 'barked', 'at', 'the', 'persian', 'cat']
[('the', 'DT'), ('little', 'JJ'), ('yellow', 'JJ'), ('dog', 'NN'), ('barked', 'VB
D'), ('at', 'IN'), ('the', 'DT'), ('persian', 'JJ'), ('cat', 'NN')]
['little', 'yellow', 'dog', 'barked', 'persian', 'cat']
```

# 한글!

### In [2]:

```
!pip install konlpy
```

Requirement already satisfied: konlpy in c:\mathbb{W}programdata\mathbb{W}anaconda3\mathbb{W}lib\mathbb{W}site-package s (0.5.1)

Requirement already satisfied: JPype1>=0.5.7 in c:\u00ecprogramdata\u00fcanaconda3\u00fclib\u00fcsite-packages (from konlpy) (0.6.3)

### In [33]:

```
from konlpy.tag import Hannanum, Kkma, Komoran, Okt
#ex ) 아이폰 을 아이. 폰으로 분석하는 건 별 필요 x
#띄어쓰기 성능
#kkma = komoran > okt > hannanum
sentence1 = "아버지가방에들어가신다"
# 형태소 분석
#kkma = komoran >
sentence2 = "아버지가 방에 들어가신다"
# 신조어/비속어
sentence3 = "아이폰 갤럭시 안드로이드 창렬하다 혜자스럽게"
hannanum = Hannanum()
print(hannanum.pos(sentence1). "₩n")
print(hannanum.pos(sentence2). "\n")
print(hannanum.pos(sentence3). "₩n")
okt = 0kt()
print(okt.pos(sentence1), "\n")
print(okt.pos(sentence2). "\n")
print(okt.pos(sentence3), "\n")
kom = Komoran()
print(kom.pos(sentence1), "\m")
print(kom.pos(sentence2), "\n")
print(kom.pos(sentence3), "\n")
ma = Kkma()
print(ma.pos(sentence1), "\n")
print(ma.pos(sentence2), "\n")
print(ma.pos(sentence3), "\n")
```

```
[('아버지가방에들어가', 'N'), ('이', 'J'), ('시ㄴ다', 'E')]
```

[('아버지', 'N'), ('가', 'J'), ('방', 'N'), ('에', 'J'), ('들', 'P'), ('어', 'E'), ('가', 'P'), ('시ㄴ다', 'E')]

[('아이폰', 'N'), ('갤럭시', 'N'), ('안드로이드', 'N'), ('창렬하다', 'N'), ('혜자스럽', 'N'), ('게', 'J')]

「('아버지', 'Noun'), ('가방', 'Noun'), ('에', 'Josa'), ('들어가신다', 'Verb')]

[('아버지', 'Noun'), ('가', 'Josa'), ('방', 'Noun'), ('에', 'Josa'), ('들어가신다', 'Verb')]

[('아이폰', 'Noun'), ('갤럭시', 'Noun'), ('안드로이드', 'Noun'), ('창렬하', 'Noun'), ('다', 'Josa'), ('혜자', 'Noun'), ('스럽게', 'Josa')]

[('아버지', 'NNG'), ('가방', 'NNP'), ('에', 'JKB'), ('들어가', 'VV'), ('시', 'EP'), ('ㄴ다', 'EC')]

[('아버지', 'NNG'), ('가', 'JKS'), ('방', 'NNG'), ('에', 'JKB'), ('들어가', 'VV'), ('시', 'EP'), ('ㄴ다', 'EC')]

[('아이폰', 'NNP'), ('갤럭시', 'NNP'), ('안드로이드', 'NNP'), ('창려', 'NNP'), ('ㄹ', 'JKO'), ('하', 'VV'), ('다', 'EC'), ('혜자', 'NNP'), ('스럽', 'XSA'), ('게', 'EC')]

[('아버지', 'NNG'), ('가방', 'NNG'), ('에', 'JKM'), ('들어가', 'VV'), ('시', 'EPH'), ('ㄴ다', 'EFN')]

[('아버지', 'NNG'), ('가', 'JKS'), ('방', 'NNG'), ('에', 'JKM'), ('들어가', 'VV'), ('시', 'EPH'), ('ㄴ다', 'EFN')]

[('아이', 'NNG'), ('폰', 'NNG'), ('개', 'VV'), ('ㄹ', 'ETD'), ('럭', 'UN'), ('시', 'NNG'), ('안', 'NNG'), ('드로', 'NNG'), ('이드', 'NNG'), ('창', 'NNG'), ('렬', 'UN'), ('하', 'XSV'), ('다', 'ECS'), ('혜', 'UN'), ('자', 'NNG'), ('스럽', 'XSA'), ('게', 'ECD')]

#### In [34]:

```
print(hannanum.tagset, "\n")
print(ma.tagset, "\n")
print(kom.tagset, "\n")
print(okt.tagset, "\n")
```

{'E': '어미', 'EC': '연결 어미', 'FF': '종결 어미', 'EP': '선어말어미', 'ET': '전성 어미', 'F': '외국어', 'I': '독립언', 'II': '감탄사', 'J': '관계언', 'JC': '격조사', 'JP': '서술격 조사', 'JX': '보조사', 'M': '수식언', 'MA': '부사', 'MM': '관형사', 'N': '체언', 'NB': '의존명사', 'NC': '보통명사', 'NN': '수사', 'NP': '대명사', 'NQ': '고유명사', 'P': '용언', 'PA': '형용사', 'PV': '동사', 'PX': '보조 용언', 'S': '기호', 'X': '접사', 'XP': '접두사', 'XS': '접미사'}

{'EC': '연결 어미', 'ECD': '의존적 연결 어미', 'ECE': '대등 연결 어미', 'ECS': '보 조적 연결 어미', 'EF': '종결 어미', 'EFA': '청유형 종결 어미', 'EFI': '감탄형 종결 어미'. 'EFN': '평서형 종결 어미'. 'EFO': '명령형 종결 어미'. 'EFQ': '의문형 종결 어미', 'EFR': '존칭형 종결 어미', 'EP': '선어말 어미', 'EPH': '존칭 선어말 어미', 'EPP': '공손 선어말 어미', 'EPT': '시제 선어말 어미', 'ET': '전성 어미', 'ETD': '관형형 전성 어미', 'ETN': '명사형 전성 어미', 'IC': '감탄사', 'JC': '접속 조사'. 'JK': '조사', 'JKC': '보격 조사', 'JKG': '관형격 조사', 'JKI': '호격 조사', 'JKM': '부사격 조사', 'JKO': '목적격 조사', 'JKQ': '인용격 조사', 'JKS': '주격 조사', 'J X': '보조사', 'MA': '부사', 'MAC': '접속 부사', 'MAG': '일반 부사', 'MD': '관형 'MDN': '수 관형사', 'MDT': '일반 관형사', 'NN': '명사', 'NNB': '일반 의존 명 사', 'NNG': '보통명사', 'NNM': '단위 의존 명사', 'NNP': '고유명사', 'NP': '대명 사', 'NR': '수사', 'OH': '한자', 'OL': '외국어', 'ON': '숫자', 'SE': '줄임표', 'S F': '마침표, 물음표, 느낌표', 'SO': '붙임표(물결,숨김,빠짐)', 'SP': '쉼표,가운뎃 점,콜론,빗금', 'SS': '따옴표,괄호표,줄표', 'SW': '기타기호 (논리수학기호,화폐기 호)', 'UN': '명사추정범주', 'VA': '형용사', 'VC': '지정사', 'VCN': "부정 지정사, 형용사 '아니다'", 'VCP': "긍정 지정사, 서술격 조사 '이다'", 'W': '동사', 'WX': '보조 용언'. 'VXA': '보조 형용사'. 'VXV': '보조 동사'. 'XP': '접두사'. 'XPN': '체 언 접두사', 'XPV': '용언 접두사', 'XR': '어근', 'XSA': '형용사 파생 접미사', 'XS N': '명사파생 접미사', 'XSV': '동사 파생 접미사'}

{'EC': '연결 어미', 'EF': '종결 어미', 'EP': '선어말어미', 'ETM': '관형형 전성 어미', 'ETN': '명사형 전성 어미', 'IC': '감탄사', 'JC': '접속 조사', 'JKB': '부사격조사', 'JKC': '보격 조사', 'JKG': '관형격 조사', 'JKO': '목적격 조사', 'JKQ': '인용격 조사', 'JKS': '주격 조사', 'JKY': '호격 조사', 'JX': '보조사', 'MAG': '일반부사', 'MAJ': '접속 부사', 'MM': '관형사', 'NN ': '분석불능범주', 'NF': '명사추정범주', 'NNB': '의존 명사', 'NNG': '일반 명사', 'NNP': '고유 명사', 'NP': '대명사', 'NN': '수사', 'NV': '용언추정범주', 'SE': '줄임표', 'SF': '마침표, 물음표, 느낌표', 'SH': '한자', 'SL': '외국어', 'SN': '숫자', 'SO': '붙임표(물결,숨김,빠짐)', 'SP': '쉼표,가운뎃점,콜론,빗금', 'SS': '따옴표,괄호표,줄표', 'SW': '기코이정사', 'W': '동사', 'W\: '청조 용언', 'XPN': '체언 접두사', 'XR': '어근', 'XSA': '형용사 파생 접미사', 'XSN': '명사파생 접미사', 'XSV': '동사 파생 접미사'}

{'Adjective': '형용사', 'Adverb': '부사', 'Alpha': '알파벳', 'Conjunction': '접속사', 'Determiner': '관형사', 'Eomi': '어미', 'Exclamation': '감탄사', 'Foreign': '외국어, 한자 및 기타기호', 'Hashtag': '트위터 해쉬태그', 'Josa': '조사', 'KoreanParticle': '(ex: ㅋㅋ)', 'Noun': '명사', 'Number': '숫자', 'PreEomi': '선어말어미', 'Punctuation': '구두점', 'ScreenName': '트위터 아이디', 'Suffix': '접미사', 'Unknown': '미등록어', 'Verb': '동사'}

### In [63]:

```
from konlpy.corpus import kolaw
corpus = kolaw.open(kolaw.fileids()[0]).read()
```

#### In [16]:

sent\_tokenize(corpus)

반수의 투표와 투표자 과반수의 찬성을 얻어야 한다.'.

- '③헌법개정안이 제2항의 찬성을 얻은 때에는 헌법개정은 확정되며, 대통령은 즉시 이를 공포하여야 한다.'.
- '펼침 부칙 <헌법 제10호, 1987.10.29.> 부칙보기\nd{Wn}\nd{Mn} 제1조 이 헌법은 1988년 2월 25 일부터 시행한다.'.
- '다만, 이 헌법을 시행하기 위하여 필요한 법률의 제정·개정과 이 헌법에 의한 대통령 및 국회의원의 선거 기타 이 헌법시행에 관한 준비는 이 헌법시행 전에 할 수 있다.'.
- '제2조 ①이 헌법에 의한 최초의 대통령선거는 이 헌법시행일 40일 전까지 실시한다.',
- '②이 헌법에 의한 최초의 대통령의 임기는 이 헌법시행일로부터 개시한다.',
- '제3조 ①이 헌법에 의한 최초의 국회의원선거는 이 헌법공포일로부터 6월 이내에 실시하며, 이 헌법에 의하여 선출된 최초의 국회의원의 임기는 국회의원선거후 이 헌법에 의한 국회의 최초의 집회일로부터 개시한다.'.
- '②이 헌법공포 당시의 국회의원의 임기는 제1항에 의한 국회의 최초의 집회일 전일까지로 한다.'.
- '제4조 ①이 헌법시행 당시의 공무원과 정부가 임명한 기업체의 임원은 이 헌법에 의하여 임명된 것으로 본다.'.
- '다만, 이 헌법에 의하여 선임방법이나 임명권자가 변경된 공무원과 대법원장 및 감사 원장은 이 헌법에 의하여 후임자가 선임될 때까지 그 직무를 행하며, 이 경우 전임자인 공무원의 임기는 후임자가 선임되는 전일까지로 한다.'.
- '②이 헌법시행 당시의 대법원장과 대법원판사가 아닌 법관은 제1항 단서의 규정에 불구하고 이 헌법에 의하여 임명된 것으로 본다.'.
- '③이 헌법중 공무원의 임기 또는 중임제한에 관한 규정은 이 헌법에 의하여 그 공무원이 최초로 선출 또는 임명된 때로부터 적용한다.'.
- '제5조 이 헌법시행 당시의 법령과 조약은 이 헌법에 위배되지 아니하는 한 그 효력을 지속한다.'.
- '제6조 이 헌법시행 당시에 이 헌법에 의하여 새로 설치될 기관의 권한에 속하는 직무를 행하고 있는 기관은 이 헌법에 의하여 새로운 기관이 설치될 때까지 존속하며 그 직무를 행한다.']

### In [97]:

```
tokens1 = list() #원사 어절
tokens2 = list() #품사분석(無量)
tokens3 = list() #품사
tokens4 = list() #품사
for sentence in sent_tokenize(corpus):
    tokens = word_tokenize(sentence)
    for token in tokens:
        tokens1.append(token)
        tokens2.extend(ma.pos(token))
        tokens3.extend([_[0] for _ in ma.pos(token)])
        tokens4.extend([_[1] for _ in ma.pos(token)])
```

#### In [37]:

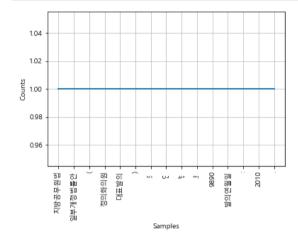
```
len(set(tokens1)), len(set(tokens2)), len(set(tokens3)), len(set(tokens4))
```

### Out[37]:

(2023, 1263, 1230, 39)

#### In [100]:

```
print(Text(tokens).plot(50))
```



#### None

### In [39]:

```
print(kom.morphs("아버지가 방에 들어가신다."), "\n")
print(kom.pos("아버지가 방에 들어가신다."), "\n")
print(kom.nouns("아버지가 방에 들어가신다. 아버지가 방에 들어가신다."), "\n")
```

```
['아버지', '가', '방', '에', '들어가', '시', 'ㄴ다', '.']

[('아버지', 'NNG'), ('가', 'JKS'), ('방', 'NNG'), ('에', 'JKB'), ('들어가', 'W'), ('시', 'EP'), ('ㄴ다', 'EF'), ('.', 'SF')]

['아버지', '방', '아버지', '방']
```

### In [40]:

Kkma().nouns("아버지가 방에 들어가신다. 아버지가 방에 들어가신다.")

#### Out [40]:

['아버지', '방']

### In [71]:

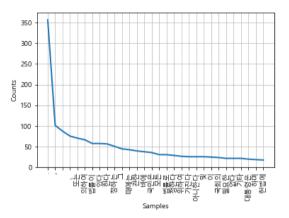
```
print(font)
```

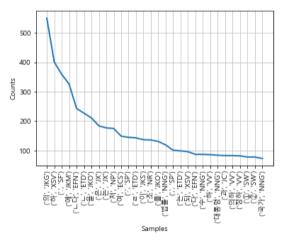
NanumBarunGothic

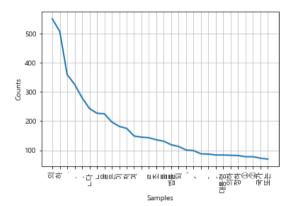
# In [72]:

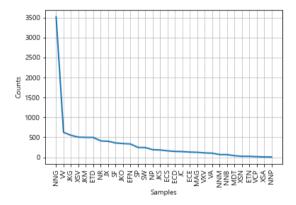
```
#plt.rcParams["font.family"] = 'NanumBarunGothicOTF'
# path = 'C:/Windows/Fonts/malgun.ttf'
# font = font_manager. FontProperties(fname=path).get_name()
# rc('font', family=font)

Text(tokens1).plot(30), Text(tokens2).plot(30), Text(tokens3).plot(30), W
Text(tokens4).plot(30)
```









### Out[72]:

(None, None, None, None)

### In [43]:

```
from nltk.probability import FreqDist
FreqDist()
```

### Out [43]:

FreqDist({})

### In [74]:

```
tokens1 = FreqDist(tokens1) #원시 어절
tokens2 = FreqDist(tokens2) #품사분석(류플)
tokens3 = FreqDist(tokens3) #형태소
tokens4 = FreqDist(tokens4) #품사
# for sentence in sent_tokenize(corpus):
# tokens = word_tokenize(sentence)
# for token in tokens:
# tokens1.append(token)
# tokens2.extend(ma.pos(token))
# tokens3.extend([[0] for _ in ma.pos(token)])
# tokens4.extend([[1] for _ in ma.pos(token)])
```

### In [75]:

```
(tokens1.N(), tokens1.B()), ₩ (tokens2.N(), tokens3.B()), ₩ (tokens3.N(), tokens3.B()), ₩ (tokens4.N(), tokens4.B())
```

### Out [75]:

```
((4640, 2023), (10081, 1263), (10081, 1230), (10081, 39))
```

### In [76]:

```
tokens2[tokens2.max()]
tokens2.freq(tokens2.max())
```

### Out[76]:

0.054558079555599645

## In [77]:

```
x = [_[0] for _ in tokens1.most_common(50)]
#range(1, 51)
y = [_[1] for _ in tokens1.most_common(50)]
```

# In [78]:

х, у

# Out [78]:

```
(['.',
'수',
'①',
 '또는',
  '의하여',
  '법률이',
  '있다',
  '한다',
  '정하는',
  '¬',
  '때에는',
  '관한',
  '바에',
  '국민은',
  '모든',
  '법률로',
  '정한다',
  '위하여',
  '가진다',
  '아니한다',
  '및',
  '01',
  '국회의',
  '필요한',
  '없다',
  '기타',
  '대통령은',
  '하며',
  '헌법에',
  '대통령이',
  '이를',
  '할',
  '사항은',
  '의무를',
  '국가의',
  '진다',
  '국가는',
  '이상의',
  '국회는',
  '임기는'.
  '권리를',
  '관하여',
  '법률에',
  '다만',
  '대통령의',
  '대한',
  '받지',
 '의한',
 '있어서'],
 [357,
  101,
 87,
  75,
  70,
  66,
  57,
 57,
  56,
```

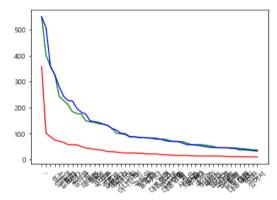
```
50,
44,
42,
39,
37,
35,
30,
30,
28,
26,
25,
25.
25,
24,
23,
21,
21,
21.
19,
18,
17,
16,
15,
15,
15.
14,
14,
13,
13,
13,
13.
13,
12,
12,
11,
11,
11,
10,
10,
```

10, 9])

# In [79]:

```
import matplotlib.pyplot as plt
n = 50

x = [_[0] for _ in tokens1.most_common(n)]
#range(1, 51)
y = [_[1] for _ in tokens1.most_common(n)]
yy = [_[1] for _ in tokens2.most_common(n)]
yyy = [_[1] for _ in tokens3.most_common(n)]
plt.plot(x, y, "r-")
plt.plot(x, yy, "g-")
plt.plot(x, yyy, "b-")
plt.xticks(rotation=45)
plt.show()
```



### In [61]:

```
temp = FreqDist()
for k,v in tokens2.items():
    if not k[1].startswith("E") and not k[1].startswith("J") and not k[1].startswith("S") W
    and len(k[0]) > 1:
        temp[k] += v

temp.most_common(n)
#[(k,v) for k, v in tokens2.items() if k[1].startswith("E")]
```

### Out[61]:

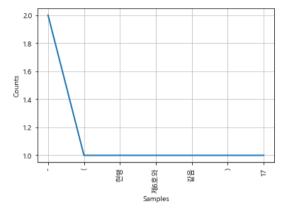
```
[(('법률', 'NNG'), 119),
(('대통령', 'NNG'), 84),
(('의하', 'VV'), 83),
(('정하', 'VV'), 82),
(('국가', 'NNG'), 73),
(('또는', 'MAG'), 70),
(('헌법', 'NNG'), 69).
(('국민', 'NNG'), 69).
(('아니하', 'VXV'), 53),
(('회의', 'NNG'), 50).
(('국회', 'NNG'), 45),
(('모든', 'MDT'), 37),
(('가지', 'VV'), 32),
(('필요', 'NNG'), 31),
(('위원', 'NNG'), 31),
(('위하', 'W'), 27),
(('선거', 'NNG'), 27),
(('기타', 'NNG'), 26),
(('보장', 'NNG'), 24),
(('국무', 'NNG'), 24),
(('정부', 'NNG'), 23),
(('사항', 'NNG'), 23),
(('자유', 'NNG'), 21),
(('권리', 'NNG'), 21),
(('의원', 'NNG'), 21),
(('대하', 'VV'), 20),
(('의무', 'NNG'), 20),
(('국회의원', 'NNG'), 20),
(('직무', 'NNG'), 19),
(('국무총리', 'NNG'), 19),
(('임명', 'NNG'), 19),
(('경제', 'NNG'), 18),
(('조직', 'NNG'), 18),
(('임기', 'NNG'), 18),
(('의결', 'NNG'), 17),
(('경우', 'NNG'), 17),
(('이상', 'NNG'), 17),
(('법원', 'NNG'), 17),
(('공무원', 'NNG'), 16),
(('단체', 'NNG'), 16),
(('범위', 'NNG'), 16),
(('보호', 'NNG'), 15),
(('이르', 'VV'), 15),
(('법관', 'NNG'), 15),
(('관하', 'VV'), 15),
(('행정', 'NNG'), 15),
(('정책', 'NNG'), 14),
(('정당', 'NNG'), 14),
(('재판소', 'NNG'), 14),
(('재판', 'NNG'), 14)]
```

### In [105]:

```
corpus = "\m".join([kobill.open(_).read() for _ in kobill.fileids()])

tokens1 = list() #원사 연절
tokens2 = list() #품사분석(無量)
tokens3 = list() #흉氏
for sentence in sent_tokenize(corpus):
    tokens = word_tokenize(sentence)
    for token in tokens:
        tokens1.append(token)
        tokens2.extend(ma.pos(token))
        tokens3.extend([_[0] for _ in ma.pos(token)])
        tokens4.extend([_[1] for _ in ma.pos(token)])

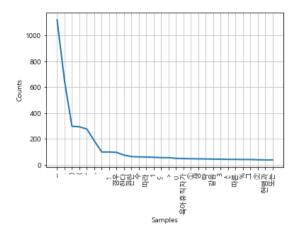
print(Text(tokens).plot(50))
```

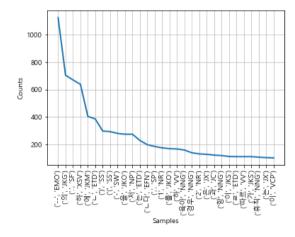


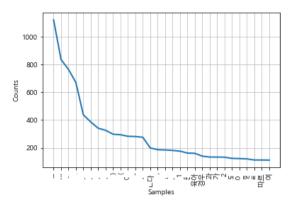
None

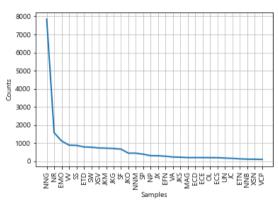
# In [106]:

```
Text(tokens1).plot(30), Text(tokens2).plot(30), Text(tokens3).plot(30), W
Text(tokens4).plot(30)
```









### Out[106]:

(None, None, None, None)

# In [107]:

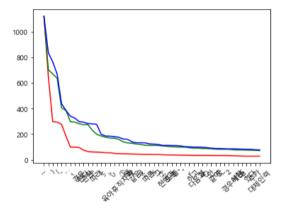
```
tokens1 = FreqDist(tokens1) #원시 어절
tokens2 = FreqDist(tokens2) #품사분석(튜플)
tokens3 = FreqDist(tokens3) #형태소
tokens4 = FreqDist(tokens4) #품사
```

### In [108]:

```
n = 50

x = [_[0] for _ in tokens1.most_common(n)]
#range(1, 51)
y = [_[1] for _ in tokens1.most_common(n)]
yy = [_[1] for _ in tokens2.most_common(n)]
yyy = [_[1] for _ in tokens3.most_common(n)]

plt.plot(x, y, "r-")
plt.plot(x, yy, "g-")
plt.plot(x, yyy, "b-")
plt.xticks(rotation=45)
plt.show()
```



# In [114]:

```
temp = FreqDist()
for k,v in tokens2.items():
    if not k[1].startswith("E") and not k[1].startswith("J") and not k[1].startswith("S") \( \text{w} \)
    and len(k[0]) > 1:
        temp[k] += v

temp.most_common(n)
```

### Out[114]:

```
[(('육아'. 'NNG'). 160).
(('경우', 'NNG'), 140).
(('따르', 'W'), 112).
(('휴직', 'NNG'), 108),
(('Olōh', 'NNG'), 91),
(('비용', 'NNG'), 82),
(('발생'. 'NNG'). 82).
(('예고'. 'NNG'). 70).
(('10', 'NR'), 69),
(('휴직자'. 'NNG'). 68).
(('결혼', 'NNG'), 66),
(('부대', 'NNG'), 65),
(('대체', 'NNG'), 64),
(('공무원', 'NNG'), 63),
(('파견', 'NNG'), 63).
(('다음', 'NNG'), 60),
(('고용', 'NNG'), 60),
(('사항', 'NNG'), 55),
(('자녀', 'NNG'), 54),
(('인력', 'NNG'), 49),
(('교육', 'NNG'), 48),
(('행정', 'NNG'), 48),
(('2011', 'NR'), 47),
(('개정', 'NNG'), 46),
(('현행', 'NNG'), 46),
(('법률', 'NNG'), 44),
(('법령', 'NNG'), 43),
(('중개', 'NNG'), 42),
(('가정', 'NNG'), 39),
(('입법', 'NNG'), 39),
(('또는', 'MAG'), 38),
(('국제', 'NNG'), 37),
(('해당', 'NNG'), 36),
(('지급', 'NNG'), 36),
(('월급', 'NNG'), 36),
(('이상', 'NNG'), 35),
(('내용', 'NNG'), 33),
(('같이', 'MAG'), 33),
(('추가', 'NNG'), 33),
(('일부', 'NNG'), 32),
(('11', 'NR'), 32),
(('급여액', 'NNG'), 32),
(('대하', 'VV'), 32),
(('필요', 'NNG'), 31),
(('연령', 'NNG'), 31),
(('12', 'NR'), 29),
(('관련', 'NNG'), 29),
(('정책', 'NNG'), 29),
(('업자', 'NNG'), 29),
(('여액', 'NNG'), 28)]
```

#### In [115]:

```
from nltk.collocations import BigramCollocationFinder, BigramAssocMeasures

bigram = BigramCollocationFinder.from_words(temp)

#bigram.nbest(BigramAssocMeasures().chi_sq, 10)

bigram.nbest(BigramAssocMeasures.pmi, 10)
```

### Out[115]:

```
[(('-4649', 'NR'), ('tanzania', '0L')), (('-5', 'NR'), ('자나', 'VV')), (('-50', 'NR'), ('공의', 'NNG')), (('0.056', 'NR'), ('0.6', 'NR')), (('0.6', 'NR'), ('10.7', 'NR')), (('01', 'NR'), ('28', 'NR')), (('02', 'NR'), ('748', 'NR')), (('02-788', '0L'), ('-4649', 'NR')), (('05', 'NR'), ('35', 'NR'), ('06', 'NR'))]
```